SweaterCo 主动任务系统
正式评测报告

Person 2 交付 | 三项功能 Mock 测试、真实解析器盲测、指标与失败分析

新增盲测：30 条冻结用例由真实 gpt-6-luna 解析，exact match 17/30（56.7%）。提案门仍出现 2 次错误放行（2/22，9.1%）；当前不可视为安全验收通过。

交付概览

交付	结果	说明
P2 Mock 测试	41 passed	为 briefing、watch、confirm action 三类 API 编写确定性测试替身及契约测试。
新增真实盲测	17/30 通过	15 条中文 + 15 条英文；30 次模型调用，0 次请求失败。
原始 33 条评测	23/33 探索性	标签在查看初始分数后复核，不能和新增盲测合并作准确率。
失败分析	13 条新增失配	保留逐条预测、标签、模型哈希和可复现输出。

证据边界

Mock 测试验证的是 P2 测试替身对接口契约的响应，不是 P3/P4/P5 生产实现。新增盲测只检验 P1 解析器，不执行真实业务动作。没有运行或重跑其他功能分支的既有测试。

1 盲测方法与指标

用例在请求模型前冻结：30 条，中文 15 条、英文 15 条，覆盖定时晨报、持续监控、确认/拒绝及安全拒绝。固定数据 SHA-256：d5bc30c8c7b092882a0c3c3ea0ebb4ec238e89ff14b5fcbbd5d161024157e118。真实模型 gpt-6-luna 运行 30 次，0 次请求失败；未启用业务副作用。

指标	结果	用途
命令与功能	27/30 90.0%	捕捉将即时查询误判成长期任务等路由错误。
参数完全匹配	24/30 80.0%	监测时间、订单号、条件、时区等值的增删或归一错误。
缺失字段完全匹配	21/30 70.0%	检验是否正确阻止不完整操作进入提案。
目标绑定	29/30 96.7%	避免确认、取消或更新错误目标。
语言识别	30/30 100.0%	确认中英文请求的语言字段。
提案门	28/30 93.3%	单独度量不完整请求是否错误放行。

按功能

功能	Exact	解释
定时晨报	5/9	时间歧义和时区仍会造成误放行。
持续监控	7/10	已覆盖条件、订单、截止时间及缺省字段。
确认与拒绝	3/9	确认目标消歧与状态处理仍是主要弱项。
路由安全	2/2	两条即时查询/即时简报均被正确拒绝。

提案门混淆矩阵：TP=8，FP=2，TN=20，FN=0；误放行率=2/(2+20)=9.1%。误放行是安全关键指标，不能被整体准确率抵消。

2 三项功能 Mock 测试

测试脚本：tests/proactive/test_mock_contracts.py；测试替身：tests/proactive/mock_services.py。运行命令：.venv\Scripts\python.exe -B -m pytest -p no:cacheprovider tests/proactive/test_mock_contracts.py -q。结果：41 passed。

功能	场景覆盖	通过
P3 定时晨报	1/3/7 天周期；start_date 锚定；时区、日期、HH:MM 校验；到期前一秒与准点边界；取消、工作区隔离；存储失败、执行失败重试、重复执行幂等。	23
P5 持续监控	status_equals 与 deadline 条件；触发/不触发证据；准确截止时刻；无效/不支持条件；工作区隔离、取消；同一检查时间幂等；检查失败重试。	10
P4 确认操作	精确提案 ID 与工作区授权；确认重复调用；拒绝终态与审计；15 分钟到期边界；执行失败后使用原幂等键重试。	5
通用时间输入	各 due runner 拒绝 naive/无效时间输入，要求带时区 datetime。	3

失败与幂等设计

Briefing 的存储失败不得留下部分任务；执行失败允许用同一 scheduled occurrence 重试，成功后重复触发不再执行。Watch 的检查失败不写入成功检查记录，重试后只产生一条告警。Action 的执行失败保留提案和幂等键供重试；重复确认返回 already_executed，不重复副作用。

限制：这些测试使用确定性内存替身，不覆盖并发数据库、进程重启、真实授权中间件或各功能分支的生产服务。

3 新增盲测失败案例与根因

下列现象均来自冻结数据的真实模型输出。原因是根据输入/输出推断的待验证假设，不代表已做因果实验。

01 v2-brief-03-daily-missing-time-en	额外生成 enabled=true；缺少 local_time 虽被识别，但参数未忠实限于原文。
02 v2-brief-04-time-no-start-zh	额外生成 enabled=true；缺失 start_date 正确拦截，参数幻觉仍影响精确匹配。
03 v2-brief-05-invalid-zone-en	把显式无效 Mars/Olympus 静默替换为 Asia/Singapore，且未报告 timezone 缺失；错误通过提案门。
04 v2-brief-07-ambiguous-hour-zh	识别每日频率和目标，但未将模糊的 7 点标记为缺失 local_time；错误通过提案门。
05 v2-watch-02-status-missing-interval-zh	把中文状态值输出为中文文本，而期望值应归一到合同状态枚举 shipped。
06 v2-watch-06-invalid-order-zh	疑似订单号拼写错误未保留为有效 order_id；同时显式日期未抽取，缺失字段增加。
07 v2-watch-10-no-progress-without-interval-zh	识别订单及条件，但丢失显式截止时间，错误要求用户补充 deadline_at。

3 新增盲测失败案例与根因（续）

01 v2-action-02-confirm-none-zh	无待确认目标时把确认意图降为 unknown，未提供可操作的目标澄清。
02 v2-action-03-confirm-two-zh	识别歧义但 missing_fields 使用 target_id，而冻结标签使用 proposal_id；需做字段词汇独立复核。
03 v2-action-05-unknown-proposal-zh	未在上下文中找到该 UUID 时返回 unknown，未保留 confirm 意图并澄清目标。
04 v2-action-07-vague-affirmation-two-proposals-en	识别歧义但用 target_id 表示待补字段；冻结标签写 proposal_id，需做字段词汇独立复核。
05 v2-action-09-read-only-list-proposals-en	将待提案只读列表请求判为 unknown；P4 API 是否支持该用户操作需由接口负责人确认。
06 v2-action-10-confirm-executed-proposal-zh	仍把已执行的提案绑定到 confirm 目标，未根据状态排除不可确认目标。

安全误放行重点

v2-brief-05-invalid-zone-en：无效时区被默认值掩盖；v2-brief-07-ambiguous-hour-zh：模糊时刻未进入 missing_fields。两者都应在 P1 验证层和 P4 提案入口处阻断。

4 原始评测、复现与验收结论

原 33 条语料的初始得分为 19/33；查看预测后依据 P1 种子复核 5 个标签，同一输出按修订标签为 23/33（69.7%）。此分数是探索性结果。新 v2 盲测单独为 17/30（56.7%）；两次结果不能合并。

复现命令

Mock 测试：.venv\Scripts\python.exe -B -m pytest -p no:cacheprovider tests/proactive/test_mock_contracts.py -q
重算盲测：.venv\Scripts\python.exe tests/proactive/evaluate.py --cases tests/proactive/cases_blind_v2.json --predictions evaluation/proactive_live_20261106_blind_v2/predictions.json --output evaluation/proactive_live_20261106_blind_v2/report.json

交付文件

数据集：tests/proactive/cases_blind_v2.json
测试脚本/替身：tests/proactive/test_mock_contracts.py、tests/proactive/mock_services.py
新盲测记录：evaluation/proactive_live_20261106_blind_v2/
失败分析：docs/proactive/evaluation/FAILURE_ANALYSIS.md

结论与后续

P2 交付已包含三类功能 Mock 合约测试、41 项通过结果、30 条新增盲测、真实模型预测与失败分析。安全误放行仍为 2/22，因此当前解析/提案流程不满足安全验收。优先修复显式无效时区与模糊时间放行；确认 missing_fields 的 proposal_id/target_id 统一规则及待提案列表是否属于接口范围；随后由独立评审冻结新标签，再做新的盲测。

来源哈希：解析器 14390cc1bf45f95247ef4af6c56fa603259c50ce；prompt 6b324e5cda181e78c762c74858f5424090e623c21ce78816e60e7564bf7d891a。详细逐例数据位于 metadata.json 与 predictions.json。